

Integración de modelos de detección y estimación de profundidad para mejorar sistemas de videovigilancia inteligente

César Omar López Arteaga
Bryan José Pumayauli Evangelista

Universidad Nacional de Ingeniería
Facultad de Ciencias
Profesor: Mg. Peter Jonathan Montalvo Garcia

2026-I

1. El Problema Encontrado

Dependencia Humana en la Videovigilancia

En la actualidad, los sistemas de vigilancia tradicionales son pasivos. Requieren la intervención y supervisión constante de personal humano frente a múltiples pantallas.

Consecuencias e Impacto:

- **Fatiga Visual y Errores:** La atención humana decae significativamente tras periodos prolongados de observación.
- **Tiempos de Respuesta Lentos:** Retrasos críticos en la detección de intrusiones o eventos peligrosos.
- **Falsas Alarmas (Sistemas Básicos):** Sensores de movimiento tradicionales que se activan por mascotas o sombras, generando alertas innecesarias.

2. Solución Propuesta

Sistema de Videovigilancia Autónomo y de Bajo Costo

Automatizar la detección de situaciones de riesgo mediante la integración de un microordenador (Edge Computing) e Inteligencia Artificial, eliminando la necesidad de supervisión constante.

Objetivos Técnicos:

- **Precisión Semántica:** Utilizar redes neuronales para identificar exclusivamente si el objeto detectado es una *persona* (descartando animales u objetos).
- **Conciencia Espacial:** Calcular la distancia relativa de la persona para emitir alertas solo si cruza un umbral de proximidad de riesgo.
- **Respuesta Inmediata:** Envío automático de evidencias (fotografías) vía correo electrónico en tiempo real.

3. Marco Teórico: Detección de Objetos con YOLO

- YOLO (You Only Look Once) es una arquitectura de red neuronal convolucional (CNN) diseñada para la detección de objetos en **tiempo real**.
- **Paradigma:** Procesa la imagen entera en una sola evaluación para predecir directamente las cajas delimitadoras (Bounding Boxes) y las probabilidades de clase.
- **Optimización Edge:** Se empleó el modelo ligero **YOLO11n** exportado al formato **NCNN**, el cual está optimizado para procesadores ARM de recursos limitados como la Raspberry Pi 4B.
- La inferencia en nuestro proyecto se restringe exclusivamente a la clase "person" del dataset COCO.

El Paradigma de YOLO

El diseño se fundamenta en la ruptura conceptual introducida por Redmon et al.:

- **Problema de Regresión Único:** No separa la generación de regiones candidatas de la clasificación de objetos.
- **Inferencia Unificada (Single-Stage):** Una sola red convolucional evalúa toda la imagen simultáneamente.
- **Ventajas en Videovigilancia:**
 - Alta velocidad de procesamiento local.
 - Comprensión del contexto global, reduciendo drásticamente los falsos positivos en el fondo.





Figura: Modelo de predicción unificado (Redmon et al., 2016).


2.1. YOLO: modelo de aprendizaje profundo para detección de objetos en tiempo real



4. Marco Teórico: Estimación de Profundidad con Depth Anything

- La **estimación monocular de profundidad** predice la geometría 3D a partir de una única imagen plana 2D, eliminando la necesidad de sensores LiDAR.
- **Depth Anything V2** es un modelo fundacional avanzado. Su arquitectura no usa convoluciones clásicas, sino **Vision Transformers (ViT)**:
 - **Encoder (DINOv2)**: Analiza parches de la imagen para extraer un contexto global y semántico robusto.
 - **Decoder (DPT)**: Reconstruye estas características en un mapa de predicción densa.
- **Salida del Modelo**: Genera un mapa en escala de grises (profundidad relativa) donde cada píxel representa un valor de cercanía.
- Se implementó la versión optimizada en formato **ONNX**, garantizando un bajo consumo de memoria RAM.

2.2. Depth Anything: modelo fundacional de aprendizaje profundo para estimación monocular de profundidad en visión por computadora



5. Implementación de Hardware y Prototipo

El montaje busca mantener todos los componentes en una posición fija para obtener mediciones geométricas consistentes:

- **Raspberry Pi 4B (8 GB RAM):** Placa principal encargada de ejecutar el sistema operativo y procesar las redes neuronales.
- **Cámara Raspberry Pi NoIR:** Conectada por el bus nativo CSI, reduciendo el cuello de botella (latencia) de las cámaras USB.
- **Sensor HC-SR501:** Sensor PIR pasivo que actúa como *disparador inicial* por hardware. Solo despierta el modelo de IA si detecta calor/movimiento.
- **Case y Ventilador:** Case Argon Neo para evitar el estrangulamiento térmico (*thermal throttling*) durante inferencias pesadas.

Vista del Prototipo Físico



6. Integración y Lógica de Seguridad


Condición Estricta de Alerta

Alerta Positiva = (Movimiento PIR) + (YOLO detecta "Persona") + (Depth Anything confirma proximidad crítica).

Secuencia Lógica:

- 1 El flujo se mantiene en reposo hasta que el sensor PIR detecta actividad, ahorrando recursos computacionales.
- 2 Se toma la fotografía y se procesa simultáneamente por ambos modelos (YOLO y Depth Anything).
- 3 Se intersecta la caja delimitadora (Bounding Box) de YOLO con el mapa de profundidad, calculando el valor promedio de cercanía sobre los píxeles del intruso.
- 4 Si el valor supera el umbral pre-calibrado, se envía silenciosamente un correo electrónico adjuntando la evidencia visual.

Flujo de Trabajo del Sistema



7. Conclusiones y Limitaciones Técnicas

- **Eficiencia Energética y de Hardware:** El uso del sensor PIR como disparador (*trigger*) previene que la Raspberry Pi evalúe cuadros vacíos, evitando sobrecalentamiento.
- **Viabilidad en el Borde (Edge):** La conversión a modelos ligeros (NCNN y ONNX) a una resolución moderada de 640x480 demostró ser el equilibrio perfecto entre latencia y precisión.
- **Limitación principal:** Depth Anything calcula *profundidad relativa*. Sin una cámara estéreo calibrada de fábrica, no podemos obtener distancias en centímetros exactos, obligando a calibrar los umbrales de forma experimental.